第2章 机器学习概述

周维达 方贤 主讲

主要内容

1. 机器学习的概念和步骤
2. 机器学习的预处理环节
3. 机器学习的类型
4. 机器学习的历史和应用
5. Scikit-learn机器学习库

2.1 机器学习的概念和步骤

机器学习的思想

机器学习：从经验（实践）中学习

从大量事例中学习——吃十堑，长一智

机器学习的定义：如果一个程序可以在任务T上，随着经验E的增加，效果P也随之增加，则称这个程序可以从经验中学习

2.1.1 前言——生活中的人工智能

语音识别

人脸识别

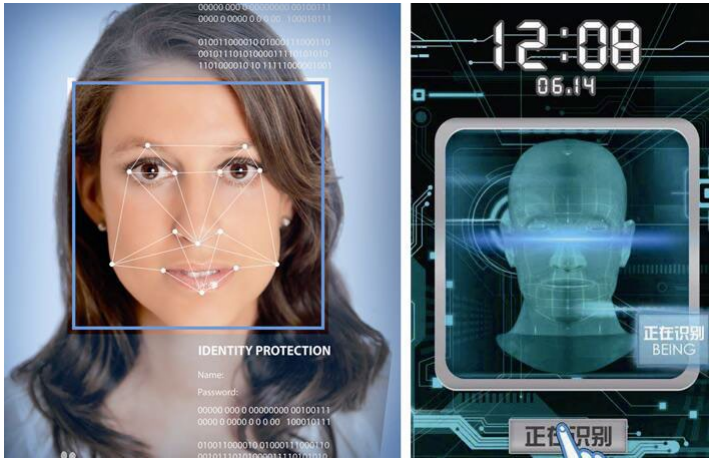

自动驾驶

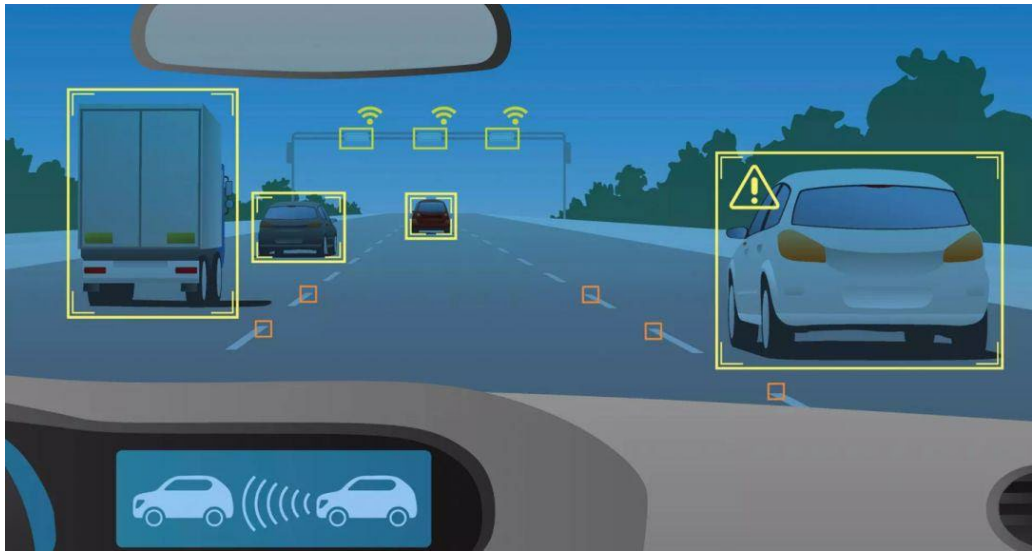

指纹识别

2.1.1 前言——人工智能与机器学习、深度学习的关系

机器学习：

是目前实现人工智能的主流方法和技术

机器学习——数据驱动的人工智能

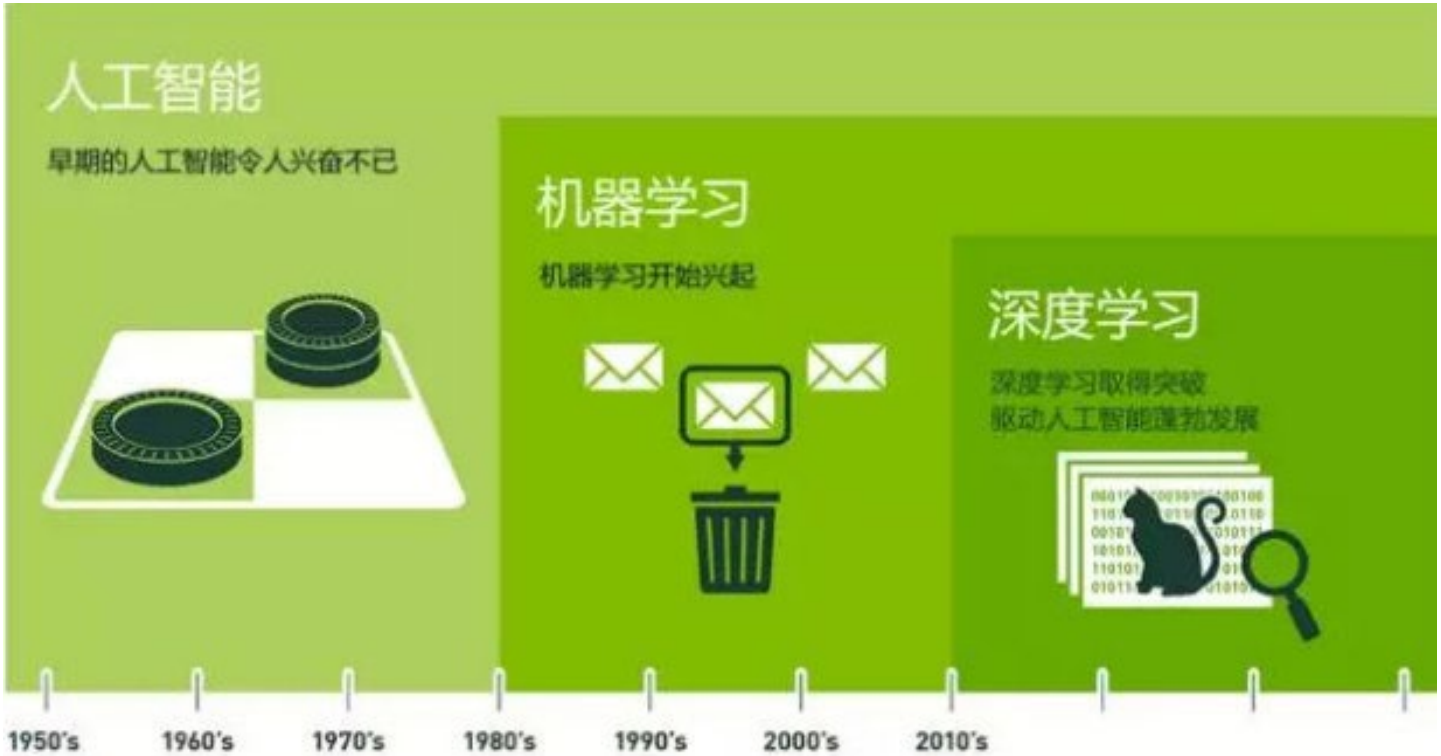

2.1.2 机器学习的一般过程——说明

从事例中学习——“事例”即“样本”

- 统计学：由样本的统计量估计总体的参数
- 机器学习：利用训练集进行建模和参数估计，利用测试集进行模型测试

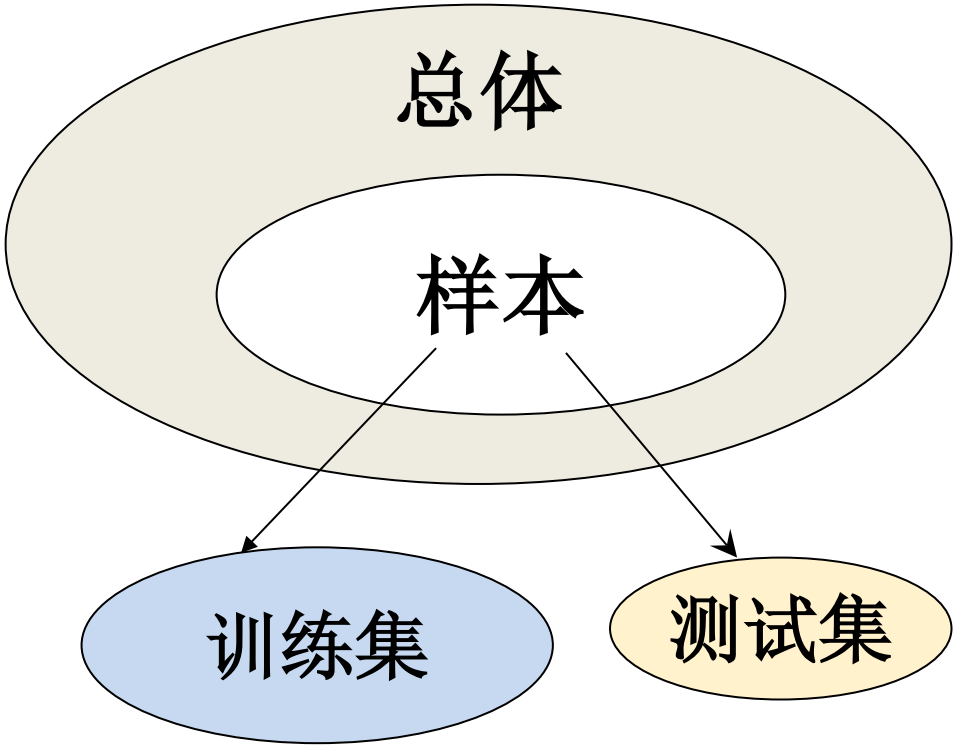

2.1.2 机器学习的一般过程——步骤示例

- 问题：让机器自动识别一个物品是筷子or牙签。(注: 机器开始并没有筷子和牙签的任何知识)
- 第一步：收集一些筷子和牙签的样本

	长度	质量	材质	类别
1	25	8	竹	筷子
2	23	7	竹	筷子
3	20	4	木	筷子
4	6	0.1	竹	牙签
5	5	0.08	竹	牙签

- 第二步：特征选择，选择有区分度的特征

2.1.2 机器学习的一般过程——步骤示例

- **第三步：训练模型**
- **训练**（training）：从数据中学得模型的过程称为**学习**（learning）或**训练**（training），这个过程通过执行某个学习算法来完成
- 训练过程中使用的数据称为**训练数据**（training data），其中每个样本称为一个**训练样本**（training sample），训练样本组成的集合称为**训练集**（training set）

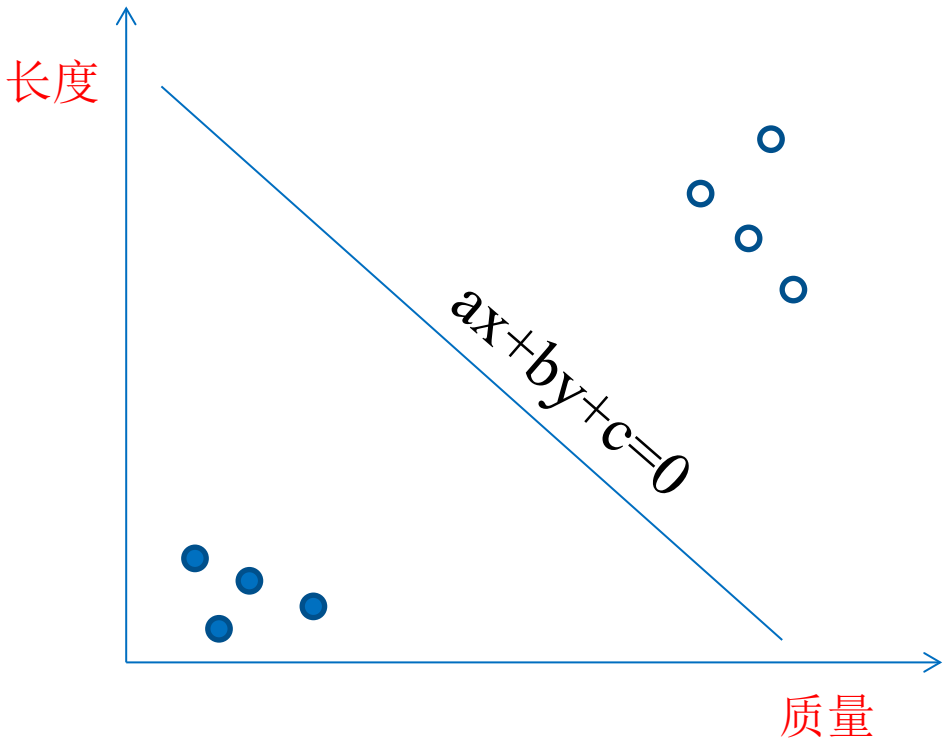

2.1.2 机器学习的一般过程——步骤示例

- **第四步：预测新实例**
- 学得模型后，使用其进行预测的过程称为**测试**（testing），被预测的样本称为**测试集**（testing sample）
- **泛化能力**（generalization）：学得模型适用于新样本的能力

模型：2x+3y-5=0

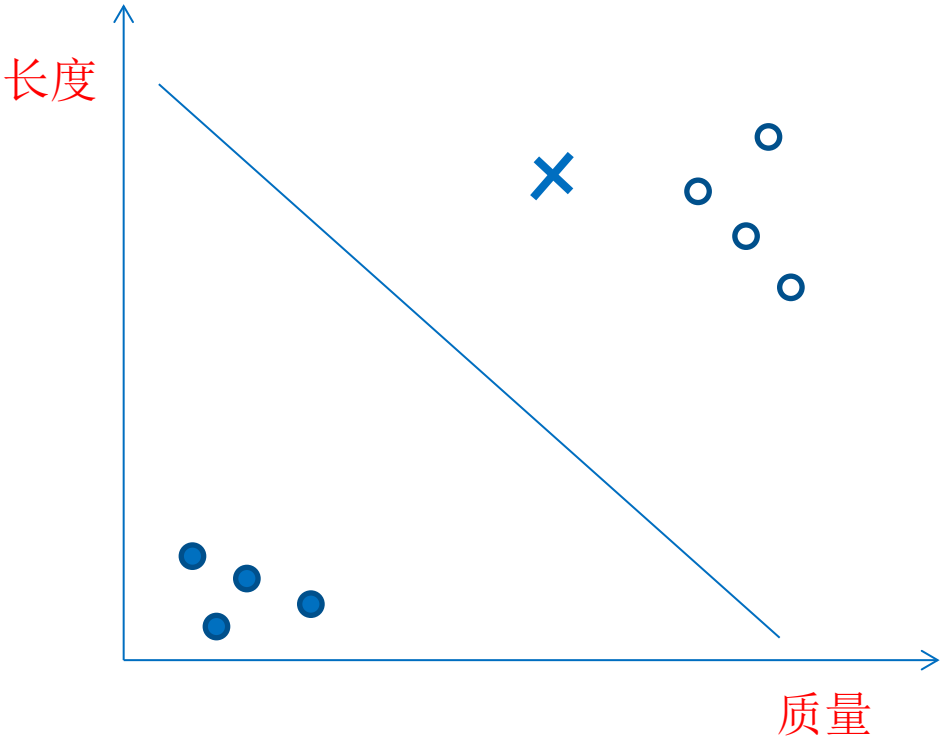

2.1.2 机器学习的一般过程——步骤总结

机器学习的步骤

收集相关样本

提取特征

训练模型

使用模型预测新样本

2.1.3 机器学习的过程举例——和传统程序的区别

不使用机器学习的传统程序

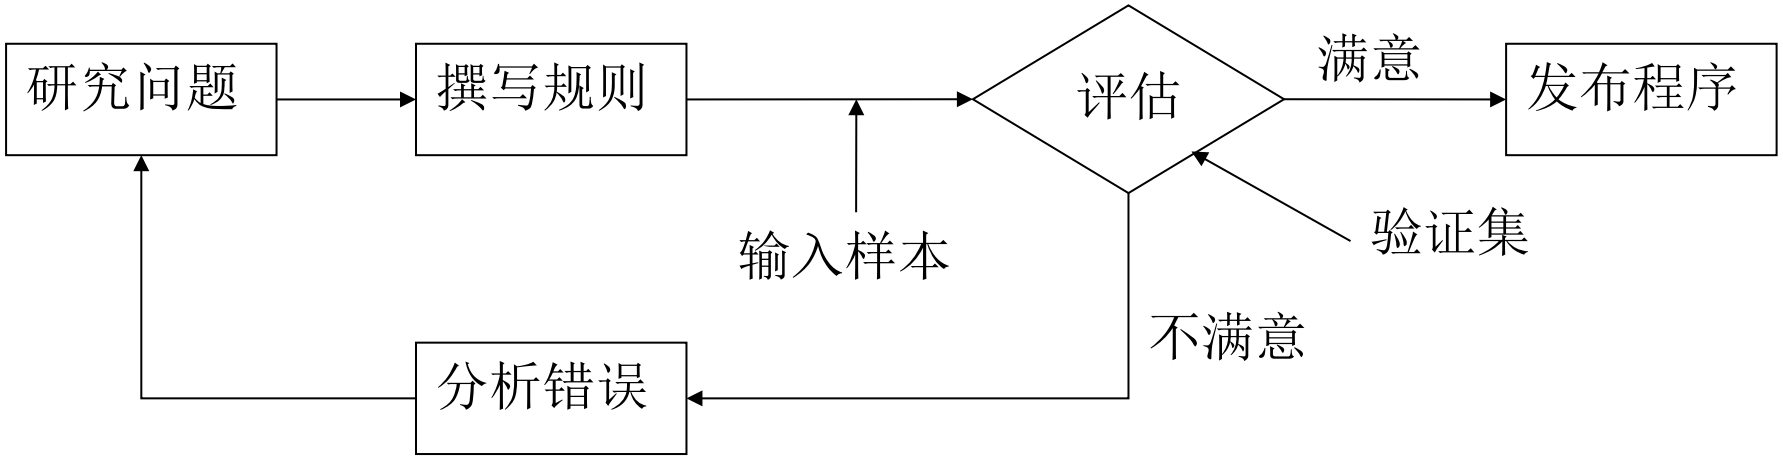

2.1.3 机器学习的过程举例——和传统程序的区别

基于机器学习的方法

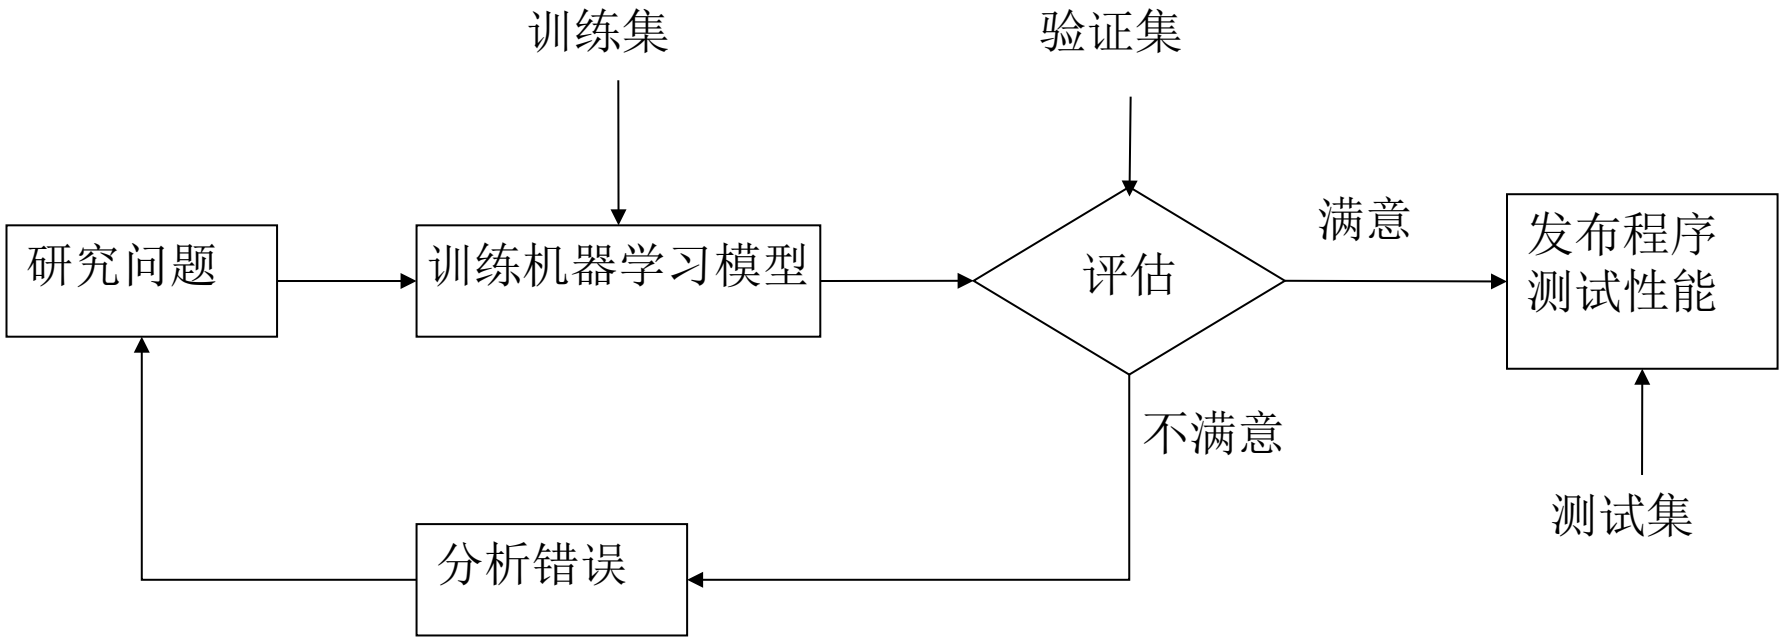

2.1.3 机器学习的过程举例——和传统程序的区别

机器学习方法能自动适应改变

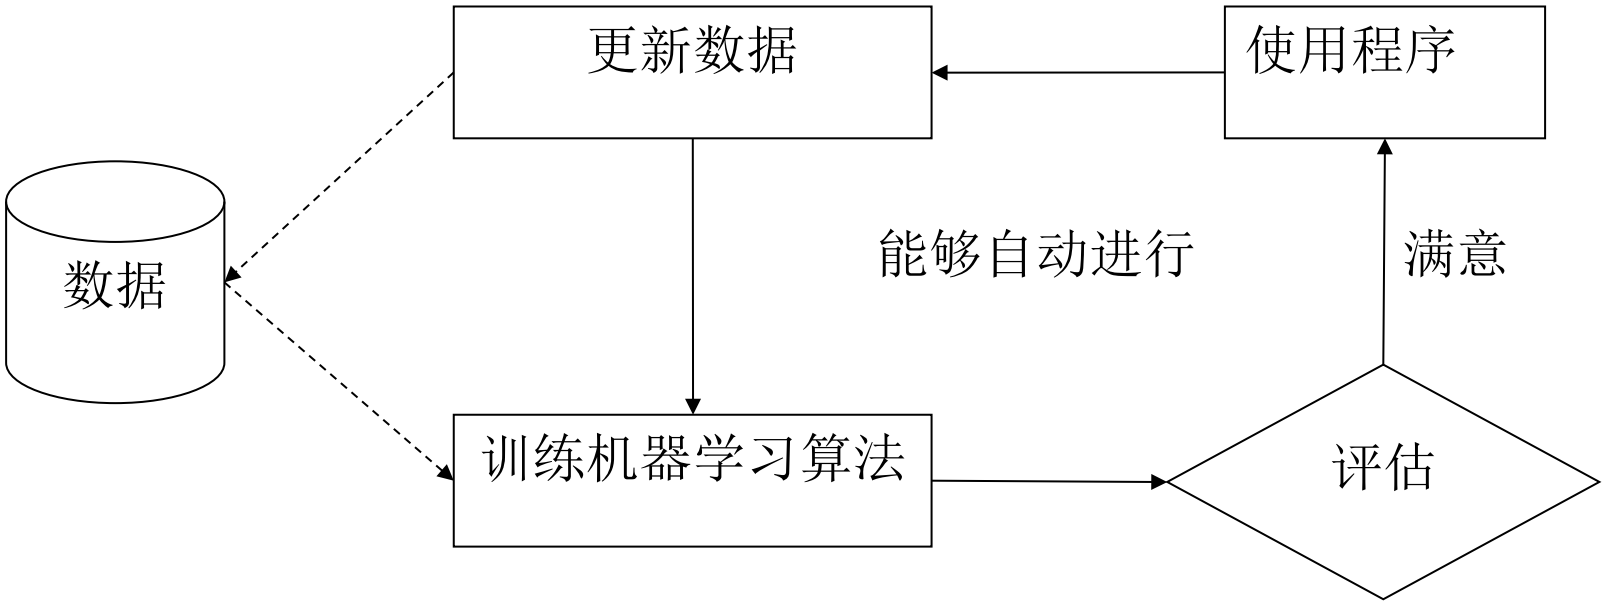

2.1.3 机器学习的过程举例——训练集、验证集和测试集

训练集、验证集，测试集

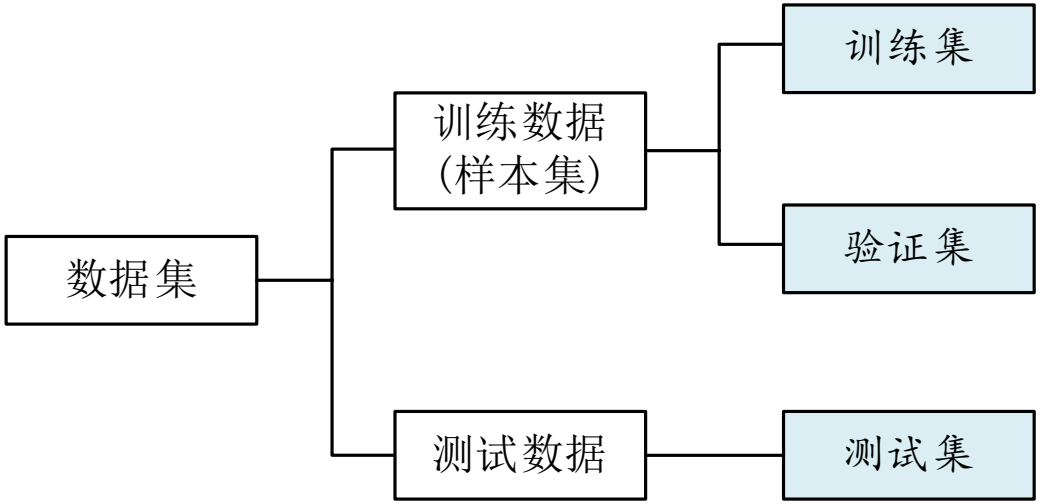

样本分为训练数据和测试数据，测试数据即为测试集，是需要应用模型进行预测的那部分数据，是机器学习所有工作的最终服务对象，为了防止训练出来的模型只对训练数据有效，一般将训练数据又分为训练集和验证集，训练集用来训练模型，而验证集一般只用来验证模型的有效性，不参与模型训练

2.1.3 机器学习的过程举例——训练集、验证集和测试集

训练集、验证集、测试集

有监督机器学习是从已有的样本中学习规律，并用来预测未知样本。它是基于这样一个假设：已有样本和未知样本中蕴含了的相同规律。同样的，将已有的样本划分为训练集和验证集，也是基于这样的假设，即训练集蕴含的规律与验证集中蕴含的规律也是一致的，因此，可以用训练集来训练模型，用验证集来验证模型，达到希望的效果后，再用来预测测试集。

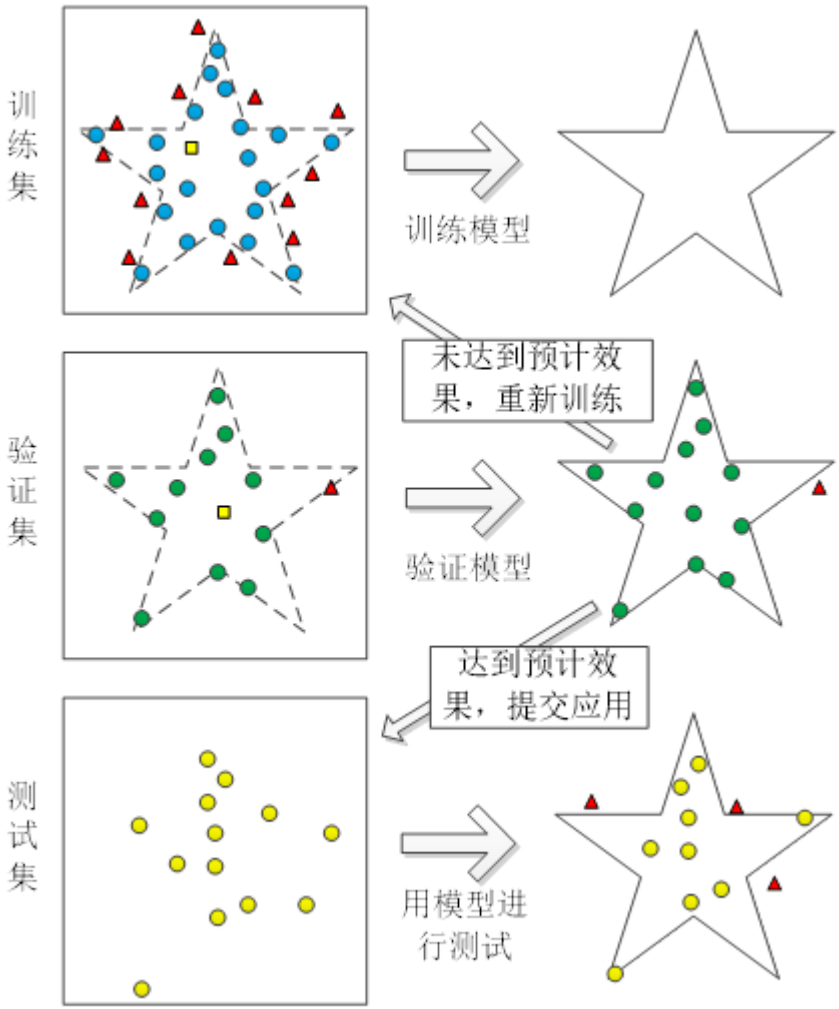

2.1.3 机器学习的过程举例——训练集、验证集和测试集

训练集、验证集的要求

首先，训练集的数据要尽可能充分且分布平衡，并符合一定的清洁度要求（即噪声不能过多）。不充分或者分布不平衡的样本集，可能不会训练出一个完整的模型。其次，验证集的样本也需要符合一定的平衡分布和清洁度要求，否则将无法验证出一个真实的模型。此外，训练模型和验证模型的样本不能相同。

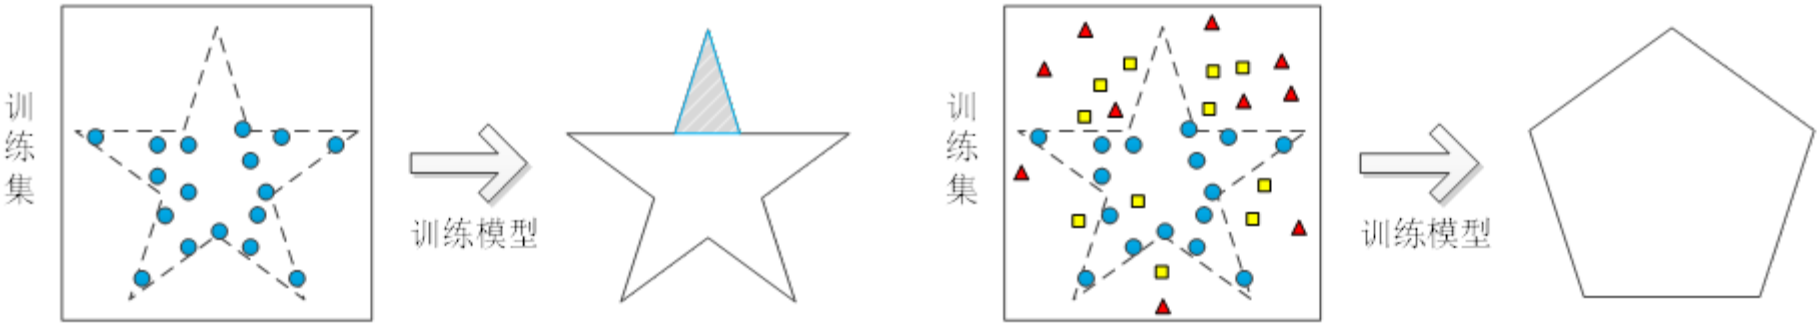

2.1.3 机器学习的过程举例——训练集、验证集和测试集

保持法、K-折交叉验证

将训练数据划分为训练集和验证集的方法称为保持法（holdout method），一般保留已知样本的20%到30%作为验证集。

K-折交叉验证是将总样本集随机地划分为K个互不相交的子集。对于每个子集，将所有其它样本集作为训练集训练出模型，将该子集作为验证集，并记录验证集每一个样本的预测结果。每个子集都这样处理完后，所有样本都有一个预测值。然后与真实值进行比对，从而评估模型的效果。这个方法将每一个样本都用来进行了验证，其评估的准确性一般要高于保持法。

2.1.4 评估机器学习模型的效果

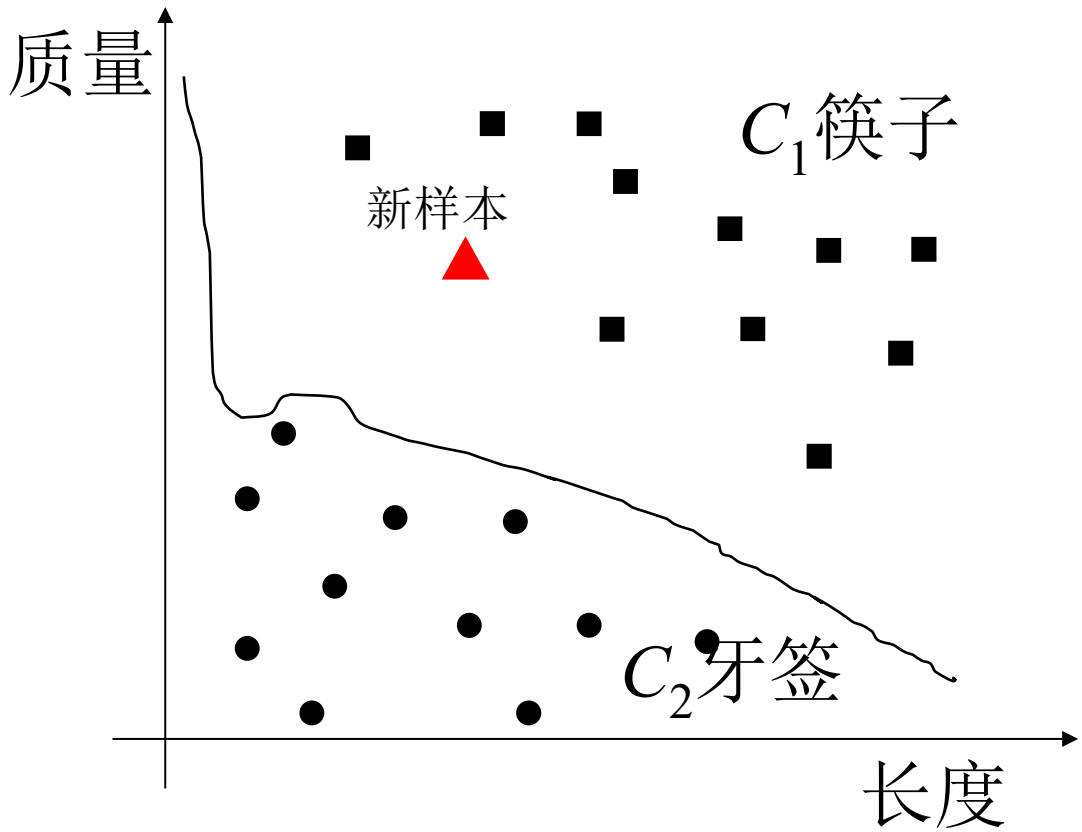

图1-6 为适应特样本而修改分类线为曲线

训练模型的最终目的是提高模型在总体（含新样本）上的预测准确率，而不是在已知样本上的预测准确率。

泛化能力是评价机器学习模型优劣的最根本指标，然而，模型的训练通常以最小化训练误差为标准。对于固定数量的训练样本，随着训练的不断进行，训练误差会不断降低，甚至趋向于零。如果模型训练误差过小，就会使训练出来的模型基本上完全适应于训练样本。

2.1.4 评估机器学习模型的效果

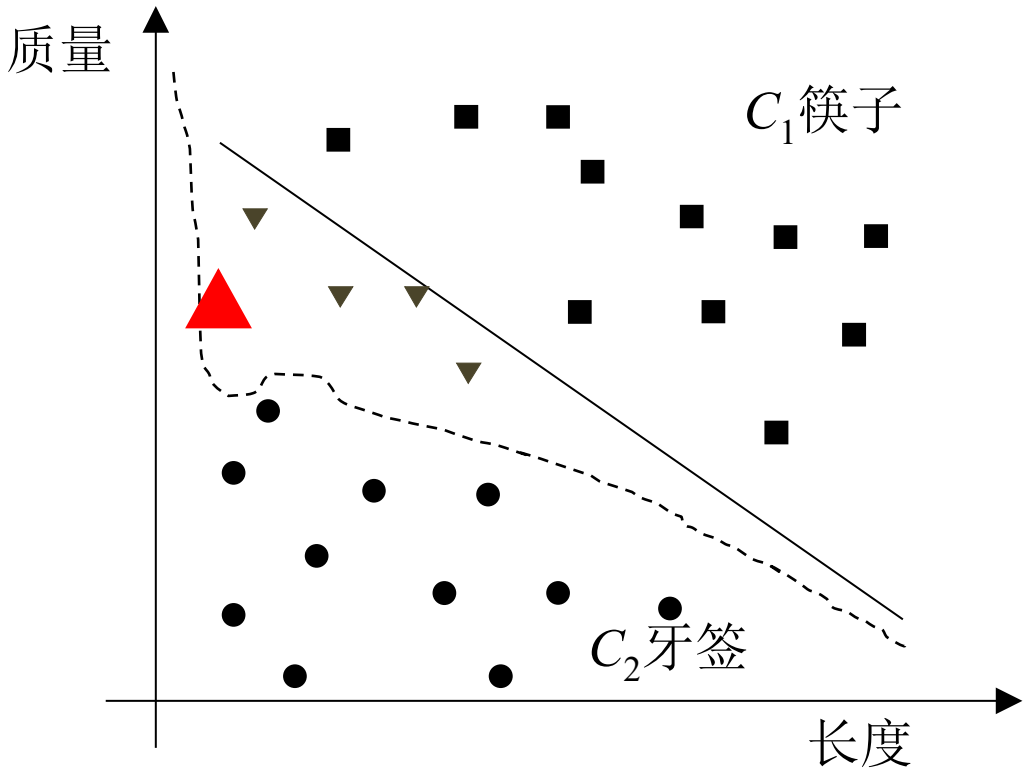

图1-7 两种分类线的预测准率对比

2.1.5 欠拟合、过拟合与泛化能力

欠拟合、过拟合示例

模型在训练样本上产生的误差叫训练误差（training error。在测试样本上产生的误差叫测试误差（test error）。

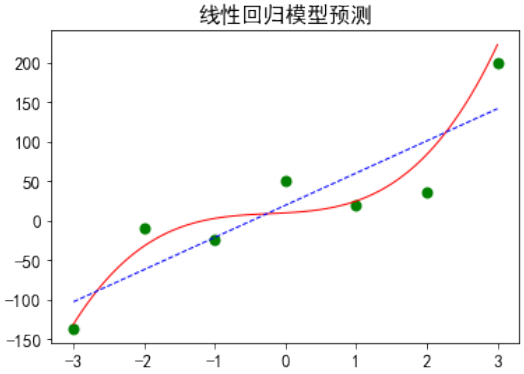

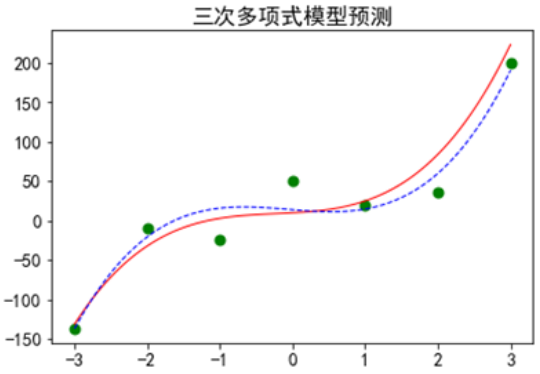

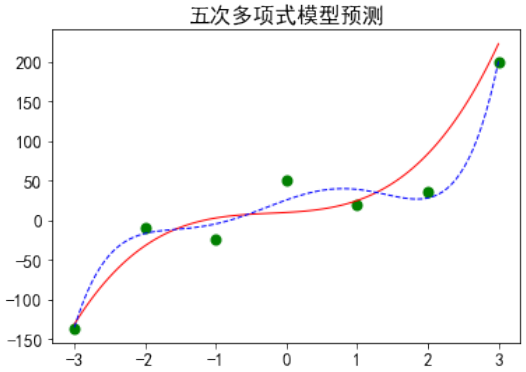

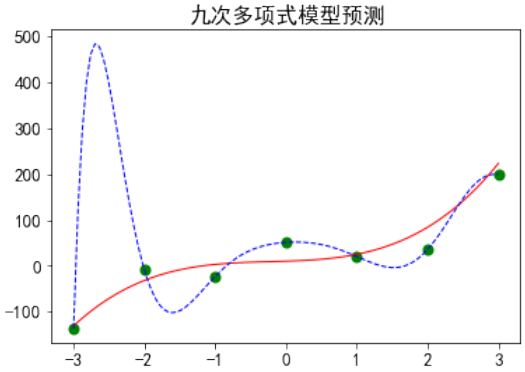

	线性回归模型	三次多项式模型	五次多项式模型	九次多项式模型
训练误差	2019	534	209	4
测试误差	578	247	1232	38492
和	2597	781	1441	38496

2.1.5 欠拟合、过拟合与泛化能力

泛化能力与模型复杂度

衡量模型好坏的是测试误差，它标志了模型对未知新实例的预测能力，因此一般追求的是测试误差最小的那个模型。模型对新实例的预测能力称为泛化能力，模型在新实例上的误差称为泛化误差。

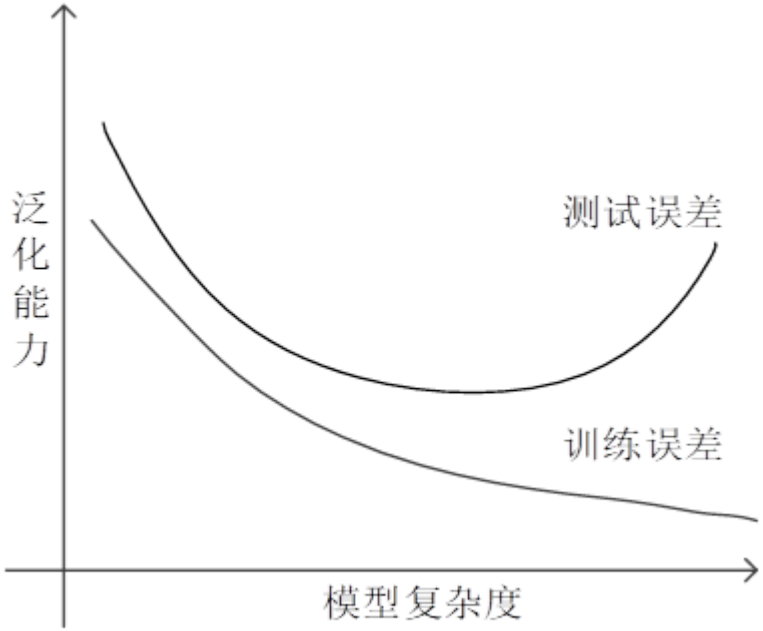

能够求解问题的模型往往不只一个。一般来说，只有合适复杂程度的模型才能最好地反映出训练集中蕴含的规律，取得最好的泛化能力。

主要内容

1. 机器学习的概念和步骤
2. 机器学习的预处理环节
3. 机器学习的类型
4. 机器学习的历史和应用
5. Scikit-learn机器学习库

2.2 机器学习的预处理环境——机器学习的工作流程

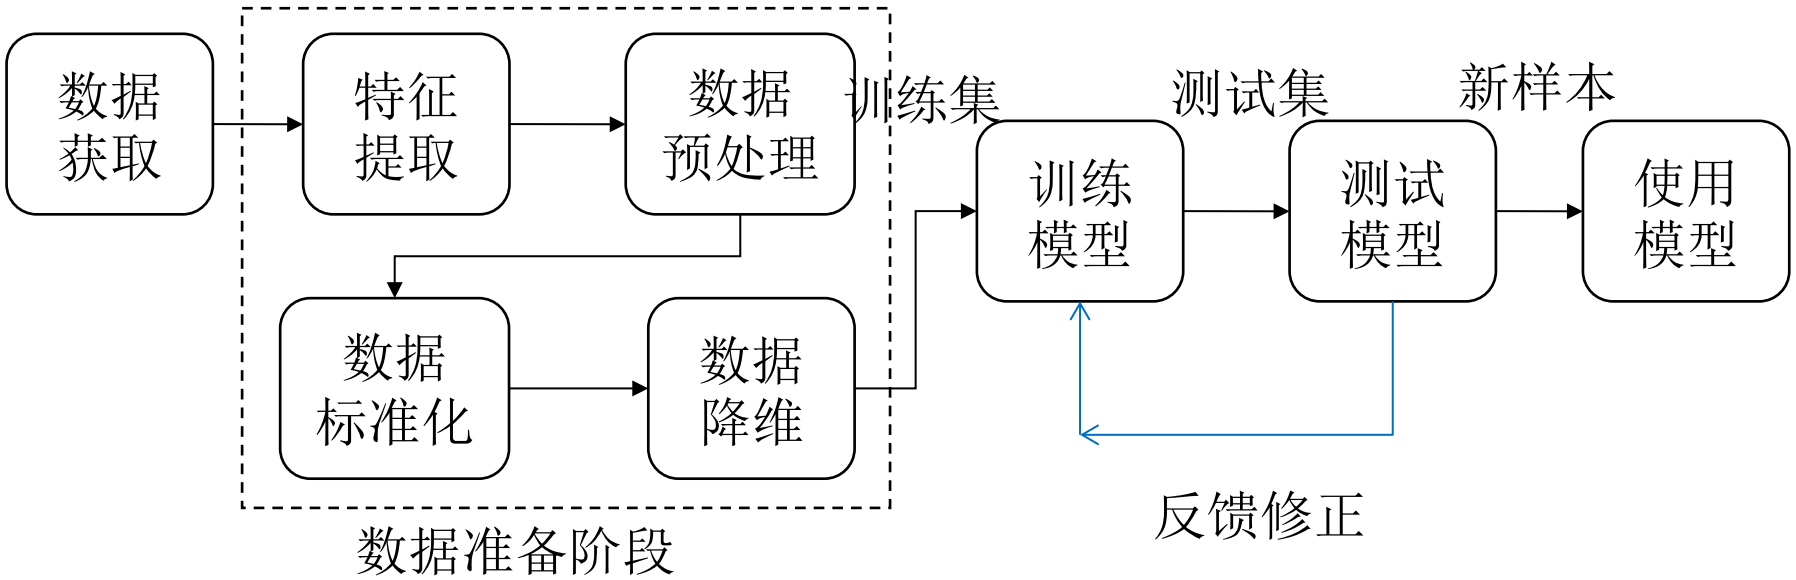

数据准备阶段是机器学习任务中繁琐枯燥但又是很重要的一个阶段

2.2.1 数据获取

数据和特征决定了机器学习的上限，而模型和算法只是逼近这个上限而已，因此数据比模型更重要

2.2.2 数据预处理

为什么要进行数据预处理：

- 获取到的原始样本数据往往会存在有缺失值、重复值等问题，在使用之前必须进行数据预处理
- 数据预处理没有标准的流程，但一般包括以下几个步骤：去除唯一属性、处理缺失值、属性编码、数据标准化、特征选择、主成分分析

2.2.2 数据预处理

对于样本数据来说，首先需要消除特征属性之间不同量级的影响：

- 数量级的差异将导致数量级较大的属性占主导地位
- 数量级的差异将导致迭代收敛速度减慢
- 依赖于样本距离的算法对于数量级非常敏感

2.2.2 数据预处理

ID	姓名	年龄	年收入	性别	学历	消费额
01	张三	36	5万	男	本科	4万1
02	李四	42	4万5	女	本科	4万
03	王涛	23	3万1	男	高中	
04	赵波	61	7万	男	本科	2万
05	钱图	38	2万	女	大专	1万

1. 去除唯一属性

2. 处理缺失值

3. 数据定量化

2.2.2 数据预处理

数据预处理之后的样本：

年龄	年收入	性别	学历	消费额
36	50000	1	80	41000
42	45000	2	80	40000
23	31000	1	40	15000
61	70000	1	80	20000
38	20000	2	60	10000

2.2.2 数据预处理

数据标准化就是用来消除不同量级的影响，常用的数据标准化方法有min-max归一化和z-score标准化两种

年龄	年收入	性别	学历	消费额
0.34	0.6	0	1	1
0.5	0.5	1	1	0.97
0	0.22	0	0	0.81
1	1	0	1	0.32
0.39	0	1	0.5	0

年龄	年收入	性别	学历	消费额
-0.33	0.40	-0.82	0.75	0.97
0.16	0.11	1.22	0.75	0.89
-1.38	-0.72	-0.82	-1.75	0.48
1.71	1.57	-0.82	0.75	0.75
-0.16	-1.36	1.22	-1.75	1.58

2.2.2 数据预处理

常用的数据预处理方法：

– min-max标准化（归一化）：

新数据=（原数据-最小值）/（最大值-最小值）

– z-score标准化（规范化）：

新数据=（原数据- 均值）/ 标准差

2.2.3 数据降维

“维度”就是指样本集中特征属性的个数，“降维”指的是降低特征矩阵中特征的数量。

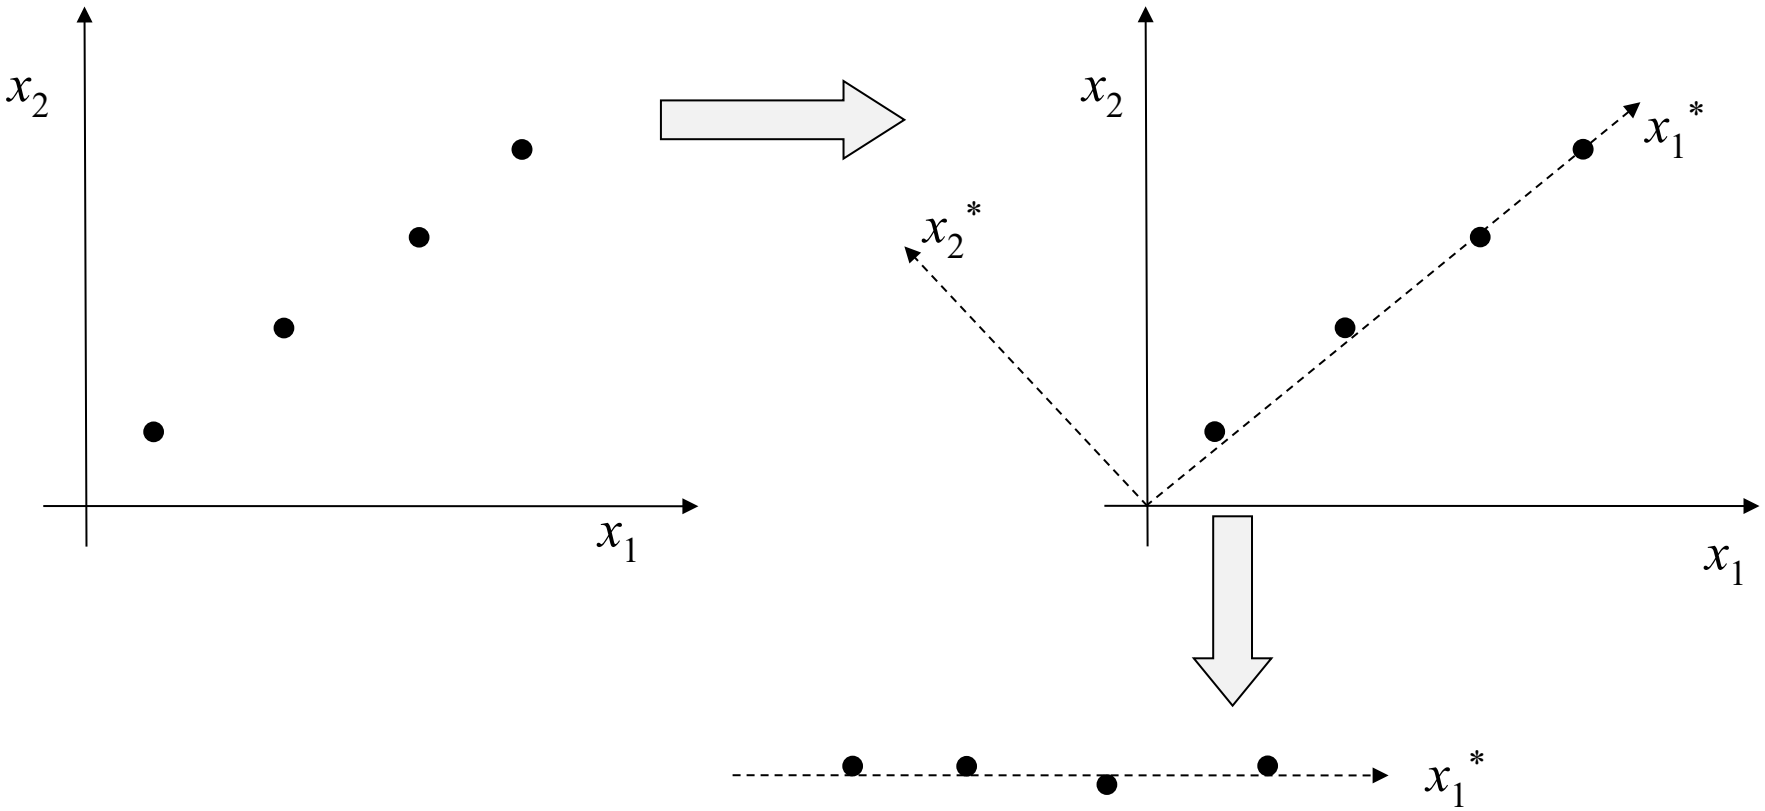

2.2.3 数据降维

维度灾难会导致分类器出现过拟合，这是因为在样本容量固定时，随着特征数量的增加，单位空间内的样本数量会变少

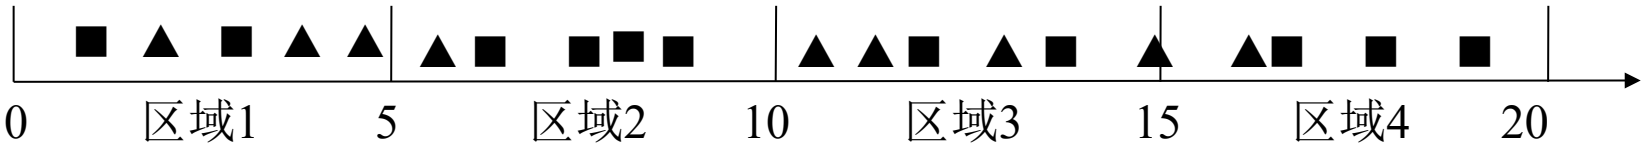

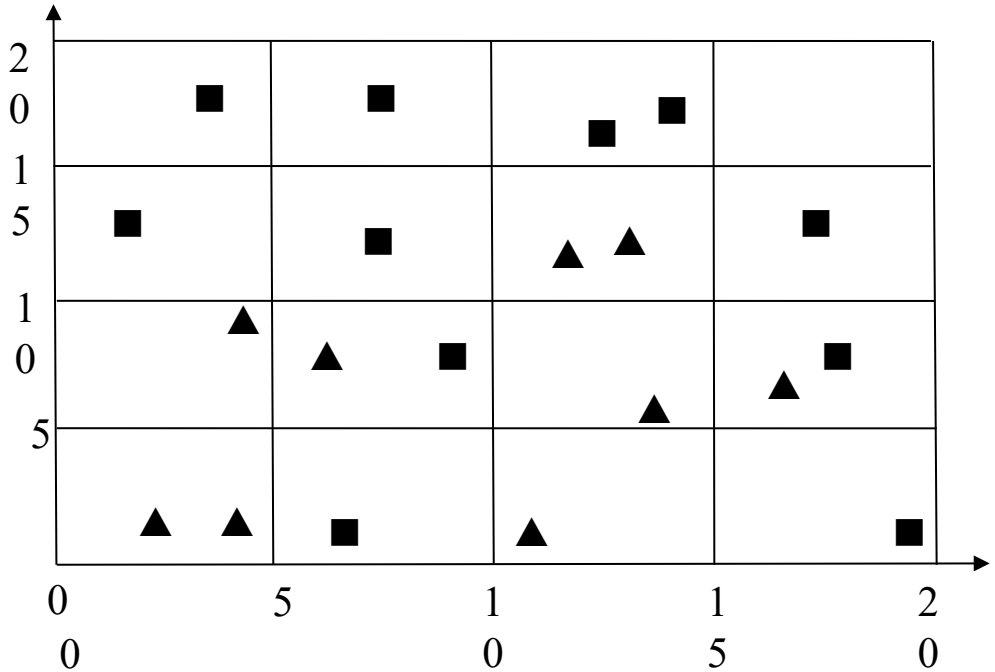

主要内容

1. 机器学习的概念和步骤
2. 机器学习的预处理环节
3. 机器学习的类型
4. 机器学习的历史和应用
5. Scikit-learn机器学习库

2.3.1 按完成的任务来看

聚类模型、分类模型、回归模型和标注模型

聚类（Clustering）模型用于将训练数据按照某种关系划分为多个簇，将关系相近的训练数据分在同一个簇中

分类（Classification）是机器学习应用中最为广泛的任务，它用于将某个事物判定为属于预先设定的多个类别中的某一个

回归（Regression）模型预测的不是属于哪一类，而是什么值，可以看作是将分类模型的类别数无限增加，即标签值不再只是几个离散的值了，而是连续的值

标注（Tagging）模型用于处理有前后关联关系的序列问题。它的输入是一个观测序列，它的输出是一个标签序列

2.3.2 按学习的过程来看

监督学习、无监督学习和半监督学习

监督学习处理的对象是所谓的有标签训练数据，它利用有标签的训练数据来学习一个模型，它的目标是用学到的模型给无标签的测试数据打上标签。

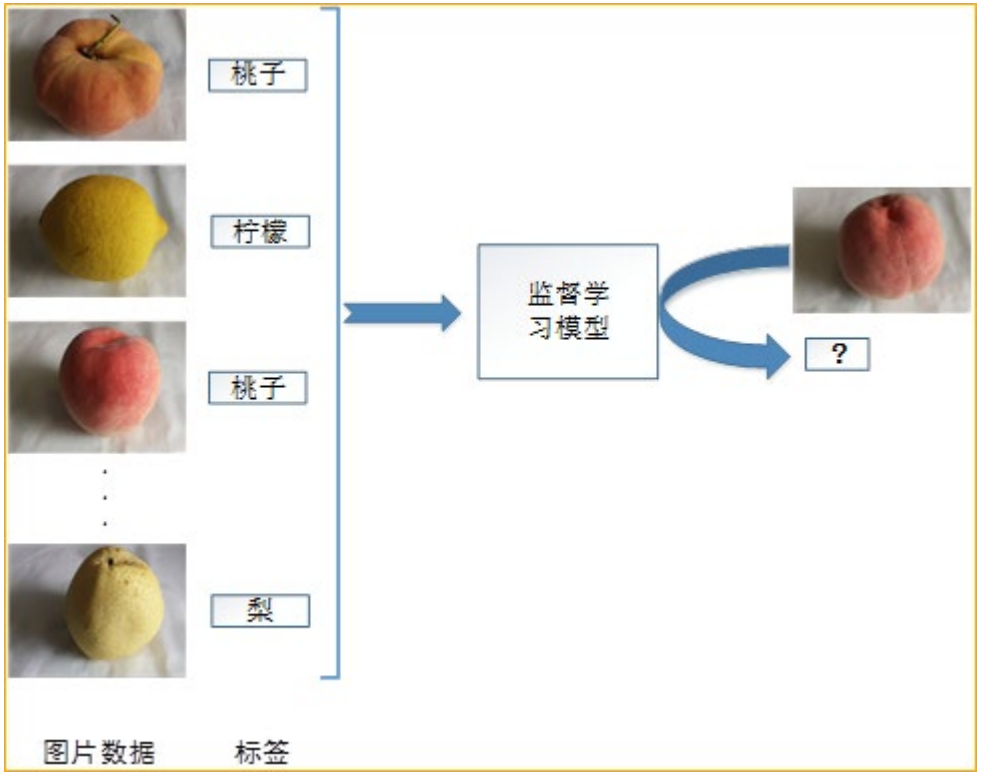

无监督学习的训练数据没有标签，它自动从训练数据中学习知识，建立模型。

半监督学习是监督学习和无监督学习相结合的一种学习方法。

主要内容

1. 机器学习的概念和步骤
2. 机器学习的预处理环节
3. 机器学习的类型
4. 机器学习的历史和应用
5. Scikit-learn机器学习库

2.4.1 机器学习的发展历史

2.4.2 机器学习的应用领域

- 语音识别

  ——GMM-HMM模型、RNN循环神经网络

- 计算机视觉

  ——深度学习模型

- 自然语言处理

  ——强化学习方法、半监督学习方法等

- 大数据分析

  ——基于机器学习对复杂多样的数据进行深层次的分析

2.4.3 机器学习的学习路线

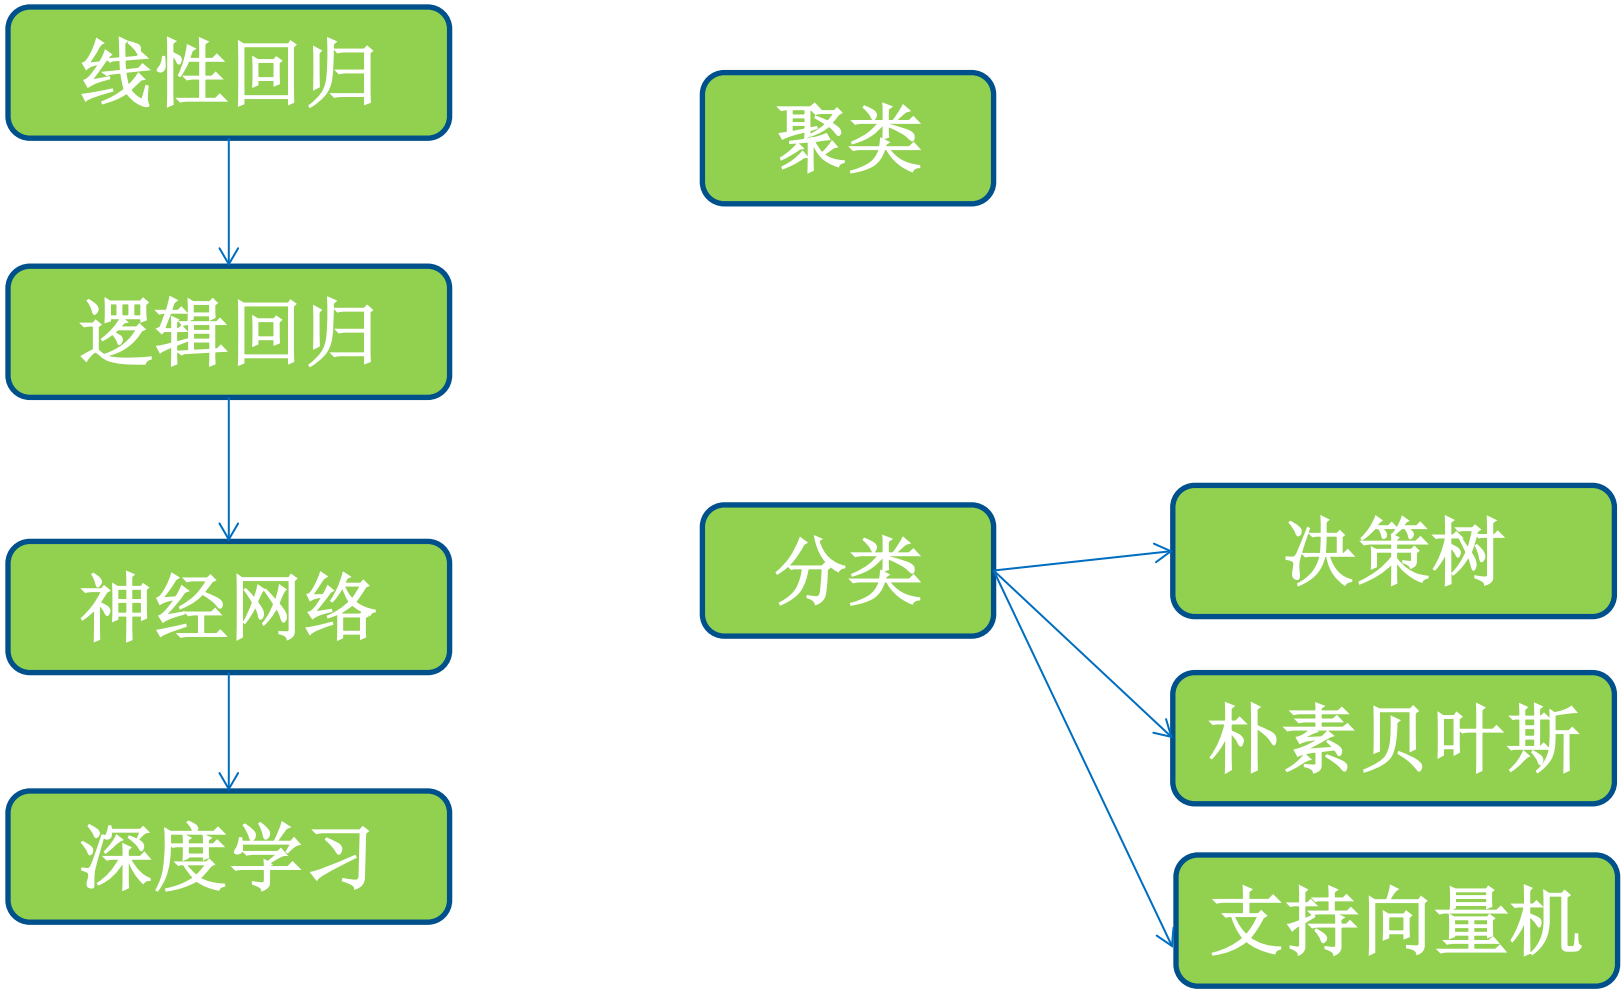

主要内容

1. 机器学习的概念和步骤
2. 机器学习的预处理环节
3. 机器学习的类型
4. 机器学习的历史和应用
5. Scikit-learn机器学习库

2.5.1 样本及样本的划分——划分样本的方法

（1）train_test_split()函数划分样本

```
from sklearn.model_selection import train_test_split
Xtrain, Xtest, Ytrain, Ytest = train_test_split(X,y,
test_size=0.3,random_state=420)
```

test_size设置测试集所占的比例

train_test_split()函数返回4个值（实际是一个元组）

2.5.1 样本及样本的划分——划分样本的方法

（2）k折交叉验证

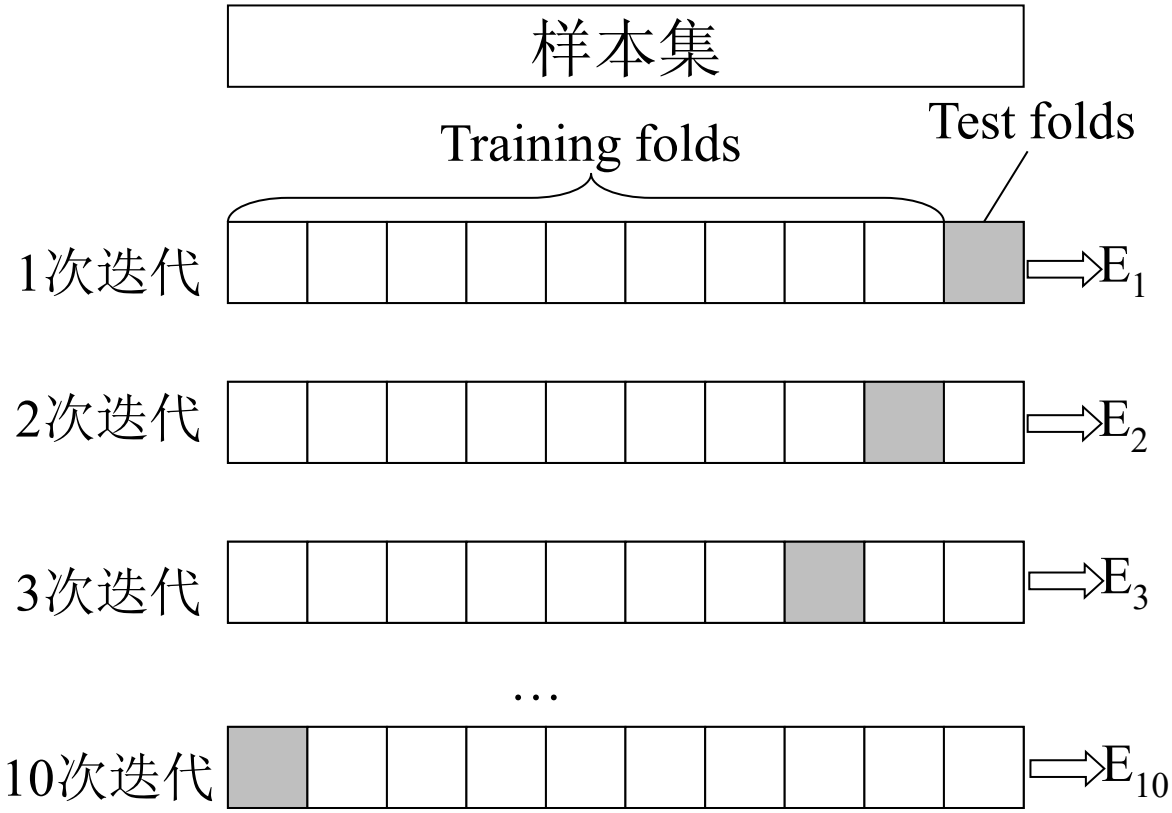

$$E = \frac{1}{10}\sum_{i=1}^{10} E_i$$

适用于小样本集的情况，将样本划分为 k个子集，每个子集均做一次测试集，其余的作为训练集。

2.5.1 样本及样本的划分——划分样本的方法

（2）k折交叉验证(续)

交叉验证函数：cross_val_predict()

```
from sklearn.model_selection import cross_val_predict
 predicted = cross_val_predict(clf, iris.data, iris.target, cv=10)
 metrics.accuracy_score(iris.target, predicted)
```

交叉验证的好处：
1）验证结果更加稳定，尤其是在小数据集中。
2）能够查看数据分布对于模型效果的影响，通过查看每份的验证结果，可以得到该数据集分布对模型的影响。
3）更好地利用训练数据，如果是5折交叉验证，那么训练量占了80%

2.5.2 导入或创建数据集

在Sklearn中，要获得或创建样本数据，有3种方法：

- 导入Sklearn自带的样本数据集
- 利用Sklearn生成随机的数据集
- 读入自己创建的数据集

2.5.2 导入或创建数据集——Sklearn自带的样本数据集

Sklearn的datasets模型中提供的样本数据集：

数据集名称	调用函数	适用	数据规模	
波士顿房价数据集	load_boston()	回归	506行*13	小
鸢尾花数据集	load_iris()	分类	150*4	小
糖尿病数据集	load_diabetes()	回归	442*10	小
体能训练数据集	load_linnerud()			
手写数字图像数据集	load_digits()	分类	5620*64	小
脸部图像数据集	fetch_olivetti_faces()	降维	400*64*64	大
新闻分类数据集	fetch_20newsgroups()	分类		大
带标签人脸数据集	fetch_lfw_people()	分类、降维		大
路透社新闻语料数据集	fetch_rcv1()	分类	804414*47236	大

2.5.2 导入或创建数据集——Sklearn自带的样本数据集

[程序2-26] 导入iris数据集

```
from sklearn.datasets import load_iris
dataSet = load_iris()    #导入iris数据集
data = dataSet['data']
label = dataSet['target']    #label标签
feature = dataSet['feature_names']
target = dataSet['target_names']
print('特征属性\n', feature , '\n类别属性\n', target)
```

运行结果

```
特征属性
['sepal length (cm)',
'sepal width (cm)', 'petal
length (cm)', 'petal
width (cm)']
类别属性
['setosa' 'versicolor'
'virginica']
```

可见iris数据集是一个有4个特征属性的三分类问题的数据集

2.5.2 导入或创建数据集——用Sklearn生成随机数据集

make_<name>函数：用来生成具有各种形状分布的数据集，这些函数可无中生有的生成随机数据：

– make_circles()：生成环形数据

– make_moons()：生成月亮形（半环形）数据

– make_blobs()：生成球型数据，多类单标签数据集

– make_classification()：多类单标签数据集，为每个类分配一个或多个正态分布的点集

– make_gaussian_quantiles()：将一个单高斯分布的点集划分为两个数量均等的点集，作为两类

– make_hastie-10-2()：产生一个相似的二元分类数据集，有10个维度

2.5.2 导入或创建数据集——用Sklearn生成随机数据集

[程序2-27] 生成随机数据集

```
from sklearn.datasets import make_circles
from sklearn.datasets import make_moons
from sklearn.datasets import make_blobs
import matplotlib.pyplot as plt
fig = plt.figure(figsize=(12, 4))
plt.subplot(1, 3, 1)
x1, y1 = make_circles(n_samples=1000, factor=0.5, noise=0.1)
plt.scatter(x1[:,0], x1[:,1], marker='o', c=y1)
plt.subplot(1, 3, 2)
x1, y1 = make_moons(n_samples=1000, noise=0.1)
plt.scatter(x1[:,0], x1[:,1], marker='o', c=y1)
plt.subplot(1, 3, 3)
x1, y1 = make_blobs(n_samples=100, n_features=2, centers=3)
plt.scatter(x1[:,0], x1[:,1], marker='o', c=y1)
plt.show()
```

运行结果

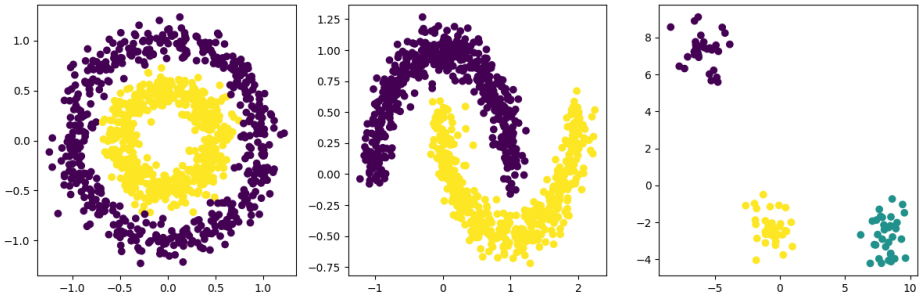

2.5.2 导入或创建数据集——读入自己创建的数据集

方法1：将数据保存到数组中

```
data = [[123, 45], [150, 55], [87, 23], [102, 34]]
target = [[250], [320], [160], [220]]
```

方法2：将数据保存到文本文件中

```
def loadDataSet():
    dataMat = []
    labelMat = []
    fr = open('C:\\lr2.txt')    #打开文本文件lr2.txt
    for line in fr.readlines():    #依次读取文本文件中的一行
        lineArr = line.strip().split()    #根据空格分割
        dataMat.append([float(lineArr[0]), float(lineArr[1])])
        labelMat.append(int(lineArr[2]))
    return dataMat, labelMat
```

2.5.2 导入或创建数据集——读入自己创建的数据集

方法3：用pandas读取excel等其他数据文件

```
import pandas as pd          #导入pandas库
data=pd.read_excel('D:\\18ds.xlsx')        #读取excel文件
data2=pd.read_csv('C:\\lr2.csv')
print(data)
```

Pandas是一个数据分析包，提供了读写文件的功能。使用pandas可以读取表格型数据，包括Excel文件、csv文件或txt文件等，并转成DataFrame类型的数据结构，然后就可以通过操作DataFrame进行数据分析，以及行和列等操作。

2.5.3 数据预处理——Sklearn中数据归一化函数

归一化函数MinMaxScaler()：

[程序2-29] 矩阵的归一化举例

```
from sklearn.preprocessing import MinMaxScaler
data = [[-1, 6], [-0.5, 2], [0, 10], [1, 18]]
scaler = MinMaxScaler()
scaler.fit(data)
MinMaxScaler(copy=True, feature_range=(0, 1))
print('range最大值为：', scaler.data_max_)
print(‘range最小值为：', scaler.data_min_)
print(scaler.transform(data))
```

运行结果

```
range最大值为：
[1. 18.]
range最小值为：
[-1. 2.]
[[0. 0.25]
[0.25 0.]
[0.5 0.5]
[1. 1.]]
```

scaler.fit(data)计算data的最小值和最大值，返回一个对象

2.5.3 数据预处理——Sklearn中数据标准化函数

z-score标准化函数StandardScaler()：

[程序2-30] 矩阵的z-score标准化

```
from sklearn.preprocessing import StandardScaler
data = [[0, 0], [0, 0], [1, 1], [1, 1]]
scaler = StandardScaler()
scaler.fit(data)
StandardScaler(copy=True, with_mean=True, with_std=True)
print(scaler.mean_)
print(scaler.var_)
print(scaler.transform(data))
print(scaler.transform([[2, 2]]))
```

运行结果

```
[0.5 0.5]
[0.25 0.25]
[[-1. -1.]
 [-1. -1.]
 [1. 1.]
 [1. 1.]]
[[3. 3.]]
```

2.5.3 数据预处理——标准化和归一化的选择

标准化：样本数据的分布要求服从正态分布

归一化的缺点：对离群值（outlier）很敏感，因为离群点会影响max或min值；其次，当有新数据加入时，可能导致max和min值发生较大变化。

而在标准化方法中，新数据加入对标准差和均值的影响并不大。

归一化会改变数据的原始距离、分布，使得归一化后的数据分布呈现类圆形。优点是数据归一化后，最优解的寻找过程会变得更平缓，更容易正确地收敛到最优解。

2.5.3 数据预处理——Sklearn中数据二值化函数

二值化函数binarizer()：

[程序2-28] 矩阵的二值化举例

```
from sklearn.preprocessing import Binarizer
X = [[ 1., -1.,2.], [ 2.,0.,0.], [ 0.,1.,-1.]]
binary = Binarizer()
transformer = binary.fit(X)
transformer.transform(X)
Binarizer(copy=True, threshold=0.0)
print(transformer.transform(X))
```

运行结果

```
[[1. 0. 1.]
 [1. 0. 0.]
 [0. 1. 0.]]
```

transformer =binary.fit(X)使用这个二值化对象的fit()方法去拟合X，返回一个二值化类的实例化对象

2.5.3 数据预处理——Sklearn中数据正则化函数

正则化函数Normalizer()：

[程序2-31] 矩阵的正则化举例

```
from sklearn.preprocessing import Normalizer
X = [[4, 1, 2, 2], [1, 3, 9, 3], [5, 7, 5, 1]]
transformer = Normalizer().fit(X)
print(transformer.transform(X))
```

运行结果

```
[[0.8 0.2 0.4 0.4]
[0.1 0.3 0.9 0.3]
[0.5 0.7 0.5 0.1]]
```

正则化是将每个样本缩放到单位范数（每个样本的范数为1），如果后面要使用如二次型（点积）或者其它核方法计算两个样本之间的相似性时这个方法会很有用

2.5.4 数据降维——主成分分析

主成分分析（Principal Component Analysis，PCA）是最常用的一种降维方法

矩阵的主成分就是其协方差矩阵对应的特征向量，按照对应的特征值大小进行排序，最大的特征值就是第一主成分，其次是第二主成分，以此类推

Sklearn的decomposition模块中提供了PCA类，用来实现主成分分析

2.5.4 数据降维——使用主成分分析降维举例

[程序2-32]对鸢尾花数据进行PCA降维

```
import matplotlib.pyplot as plt
from sklearn.decomposition import PCA
from sklearn.datasets import load_iris
data = load_iris()
y = data.target
x = data.data
pca = PCA(n_components=2)   #加载PCA算法，设置降维后维度为2
reduced_x = pca.fit_transform(x)   #对样本的特征属性集进行降维
red_x,red_y = [], []   #保存第0类样本
blue_x,blue_y = [], []   #保存第1类样本
green_x,green_y = [], []   #保存第2类样本
for i in range(len(reduced_x)):
    if y[i] ==0:  #该数据集有3个类别，因此y[i]=0,1,2
        red_x.append(reduced_x[i][0])
        red_y.append(reduced_x[i][1])
    elif y[i] == 1:
        blue_x.append(reduced_x[i][0])
        blue_y.append(reduced_x[i][1])
    else:
        green_x.append(reduced_x[i][0])
        green_y.append(reduced_x[i][1])
plt.scatter(red_x, red_y, c='r', marker='x')
plt.scatter(blue_x, blue_y, c='b', marker='D')
plt.scatter(green_x, green_y, c='g', marker='.')
plt.show()
```

运行结果

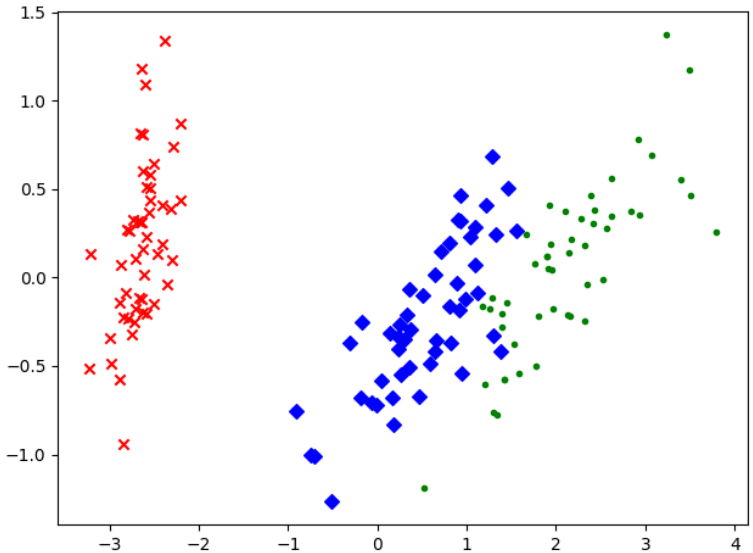

pca.fit_transform(x)计算出数据变换的方式，并返回对输入数据x变换后的结果

2.5.5 调用机器学习模型

Sklearn机器学习库中的模型种类：

- 回归：梯度下降回归（SGD）、Lasso回归、岭回归等
- 分类：朴素贝叶斯、K近邻算法（KNN）、向量机（SVM）、决策树和随机森林、逻辑回归等
- 聚类：k均值（K-means）、层次聚类（Hierarchical clustering）、DBSCAN
- 降维：主成分分析（PCA）、线性判别分析（LDA）

实际上，Sklearn中的大部分方法都属于估计器或转换器调用的方法，估计器用于对数据的预测或回归，转换器用于对数据的处理

2.5.5 调用机器学习模型——估计器（Estimator）

估计器（Estimator）其实就是模型，它用于对数据的预测或回归。估计器一般具有以下几个方法：

- 1）fit(x,y)：传入数据（X）以及标签（y）即可训练模型，对于无监督学习，调用方法是fit(X)
- 2）score(x,y)：用于对模型的正确率进行评分（分数范围是0-1）
- 3）predict(x)：用于对数据的预测，它接受输入，并输出预测标签，输出结果的格式为numpy数组

2.5.5 调用机器学习模型——转化器 (Transformer)

转化器（Transformer）用于对数据的处理，例如标准化、降维以及特征选择等。转化器具有以下方法：

- 1）fit(x,y)：该方法接受输入和标签，计算出数据变换的方式
- 2）transform(x)：根据已经计算出的变换方式，返回对输入数据x变换后的结果（不改变x）
- 3）fit_transform(x,y) :该方法在计算出数据变换方式之后对输入x就地转换